CSDN首页 (http://www.csdn.net?ref=toolbar)

学院 (http://edu.csdn.net?ref=toolbar)

下载 (http://download.csdn.net?ref=toolbar)

再多 ▼

□ 下载 CSDN APP (http://www.csdn.net/app/?ref=toolbar)

∠ 写博客 (http://write.blog.csdn.net/postedit?ref=toolbar)

# cson (http://www.csdn.net)



## Keras + LSTM + 词向量 情感分类/情感分析实验



原创 2017年03月10日 23:26:40

CC 5859





本人是深度学习入门的菜菜菜鸟一枚...

利用WSTM + word2vec词向量进行文本情感分类/情感分析实验,吸收了网上的资源和代码并尝试转化为自己的



# 实验环境

- win7 64位系统
- Anaconda 4.3.0, Python 2.7 version
- Pycharm开发环境
- python包: keras, gensim, numpy等

# 实验数据

本文的实验数据是来自网上的中文标注语料,涉及书籍、酒店、计算机、牛奶、手机、热水器六个方面的购物评 论数据,具体介绍参见该文:购物评论情感分析(http://buptldy.github.io/2016/07/20/2016-07-20sentiment%20analysis/)。

#### 数据处理

上面提到的数据在网上见到的次数比较多,原始格式是两个excel文件,如图:





neg.xls

对,就是这两个...估计来到本文的小伙伴也见过。一些代码就是直接从这两个excel里读取数据、分词、处理...不 过我表示自己习惯从txt文本里获取数据,因此本人将数据合并、去重(原数据里有不少重复的评论)、分词(用 的是哈工大LTP分词)之后存为一份txt文本,保留的数据情况如下:

正面评价个数:8680个 负面评价个数:8000个



#### 竹聿Simon (http://blog....

+ 关注

(http://blog.csdn.net/churximi)

Q

未开诵 原创 粉丝 (https://gi 78 51 utm\_sourc

#### 他的最新文章

更多文章 (http://blog.csdn.net/churximi)

Mac python IDLE不支持中文输入解决

(/churximi/article/details/73658196)

sklearn数据集随机切分

(train\_test\_split)

(/churximi/article/details/61415254)

Keras + LSTM + 词向量 情感分类/情 感分析实验

(/churximi/article/details/61210129)

【Python】利用tkFileDialog打开文件 对话框

(/churximi/article/details/61198438)



#### 在线课程



(北色费Jd派公理解DRAKEburse/detail/563?

内部原理及网络配置 utm source=blog9 php:控解和.csdn.net/hu iyiCourse/detail/563?

blog9)

和69/2017sa环块链球式ourse/series detail/

utm source=blog9) 伊斯克森氏du.csdn.net/hu iyiCourse/series\_detail/ 66?utm\_source=blog9)

#### 文本如图所示:

我 是 2月 18日 入住 中远 酒店 的 , 我 觉得 400 的 价位 性价比 非常 高 , 酒店 #蒙牛百变大咖秀#我很爱蒙牛优益。的哟\\^。^/它已经成为我生 # 送 台 ipad 给 爸妈 # 感谢 蒙牛 给 我 营养 让 我 快乐 的 成长; 感谢 蒙牛 做 1 、 屏幕 较 清晰 , 但是 亮度 不够 好 , 看 不 出 26万 色 有 什么 特别 的 地; 屏幕 细腻 、 这个 有 很多 人 说 不如 日系 产品 、 三星 等 韩系 产品 , 确 估计 看 我 这个 帖子 的 朋友 也 都 是 这样; 1. 外形 不错 。 我 喜欢 直板机 , exo-m, , 希望 在 新人 盛典 上 能 拿 到 新人奖 , 这 是 你们 和 歌迷 共同 的 梦 ∮40 是 ─ 部 以 电视 功能 为 主要 卖点 的 手机 , 上市 的 时候 也 可谓 天﴿ 哎呀 , 第一 次 在 中联榜 获得 冠军 , 心里 那个 美滋滋 、 乐呵呵 , 甜甜 的 扌 本人 购机 已经 有 一个 星期 了 , 在 这 段 时间 里 , 对 其 的 优缺点 也 有 了 必 的 , 全新 蒙牛 幸福 启航 一起 转 起来 来 了 , 终于 来 了! **誇**豣 专辑 《 年轮 》 发行 后备 受 好评 , 在 刚 公布 的 2012 年度 蒙牛 酸酸乳 小又 来 啦 , 运气 很 不错 , 被 咱们 仨 抢 到 独 三 无 四 的 蒙牛 随 变 冰 回g/蒙牛 客服 对 意见 反馈 及时 , 值得 肯定 。 期待 如 你们 所 言 , 蒙牛 成 划傷 这儿 牛奶 怎么样 呢 。 蒙牛 霸气 外露 , 特伦苏 绝对 是 蒙牛 的 老 酸奶 比如实 好吃 。 每每)必做的事就看蒙牛酸酸乳音乐风云榜它不光为我带来了好听的冒 蒙牛 .....镇 的 很 牛

然后人工生成一份【语料类别】文本,用1表示正面评价,用0表示负面评价,与评论数据——对应。

#### 文本数据下载地址:

https://github.com/churximi/Keras (https://github.com/churximi/Keras)

# 生成词语的索引字典、词向量字典

利用上述文本语料生成词语的索引字典和词向量字典。

注意:当Word2vec词频阈值设置为5时,词频小于5的词语将不会生成索引,也不会生成词向量数据。

工具: gensim里的Word2vec, Dictionary

代码

```
#!/usr/bin/env python
    # -*- coding: utf-8 -*-
  2
  3
  4
     功能:利用大语料生成词语的索引字典、词向量,然后保存为pkl文件
  6
     时间: 2017年3月8日 13:19:40
     import pickle
     import logging
     import tkFileDialog
     import numpy as np
     np. random. seed (1337) # For Reproducibility
     from Functions. TextSta import TextSta
收藏/
     from gensim.models.word2vec import Word2Vec
    from gensim, corpora, dictionary import Dictionary
20
评论
     # 创建词语字典,并返回word2vec模型中词语的索引,词向量
     def create dictionaries(p model):
        gensim_dict = Dictionary()
        gensim_dict.doc2bow(p_model.vocab.keys(), allow_update=True)
        w2indx = {v: k + 1 for k, v in gensim_dict.items()} # 词语的索引,从1开始编号
        w2vec = {word: model[word] for word in w2indx.keys()} # 词语的词向量
 25
 26
        return w2indx, w2vec
 27
 28
    logging.basicConfig(format='%(asctime)s: %(levelname)s: %(message)s', level=logging.INFO)
 30
     print u"请选择大语料的分词文本..."
 31
     T = TextSta(tkFileDialog.askopenfilename(title=u"选择文件"))
 32
     sentences = T. sen() # 获取句子列表,每个句子又是词汇的列表
 33
 34
    print u'训练Word2vec模型(可尝试修改参数)...'
 35
 36
     model = Word2Vec(sentences,
                    size=100, # 词向量维度
 37
                    min_count=5, # 词频阈值
 38
 39
                    window=5) # 窗口大小
 40
     model_name = raw_input(u"请输入保存的模型文件名...\n").decode("utf-8")
 41
     model.save(model name + u'.model') # 保存模型
 42
 44 # 索引字典、词向量字典
     index_dict, word_vectors= create_dictionaries(model)
 45
 46
    # 存储为pk1文件
 47
    pkl_name = raw_input(u"请输入保存的pkl文件名...\n").decode("utf-8")
     output = open(pkl_name + u".pkl", 'wb')
 49
     pickle.dump(index_dict, output) # 索引字典
    pickle.dump(word_vectors, output) # 词向量字典
    output.close()
 53
 54
    if __name__ == "__main__":
 55
        pass
```

#### 其中,

```
1 T = TextSta(tkFileDialog.askopenfilename(title=u"选择文件"))
2 sentences = T.sen() # 获取句子列表,每个句子又是词汇的列表
```

TextSta是我自己写的一个类,读取语料文本后,sentences = T.sen()将文本里的每一行生成一个列表,每个列表 又是词汇的列表。(这个类原来是用作句子分类的,每行是一个句子;这里每行其实是一个评论若干个句子…我就不改代码变量名了…)

TextSta类部分代码:

```
#!/usr/bin/env python
  2 # -*- coding: utf-8 -*-
  3
  4
    功能:一个类,执行文本转换
  5
     输入: 分词文本
     输出:句子列表,全文的词汇列表,TF,DF
     时间: 2016年5月17日 19:08:34
     import codecs
     import re
     import tkFileDialog
    class TextSta:
收藏/
        # 定义基本属性, 分词文本的全路径
        filename = ""
\mathbf{Q}_{9}
        # 定义构造方法
        def __init__(self, path):
                                #参数path,赋给filename
            self.filename = path
分裏
        def sen(self): # 获取句子列表
           f1 = codecs.open(self.filename, "r", encoding="utf-8")
 25
 26
            print u"已经打开文本: ", self.filename
 27
            # 获得句子列表, 其中每个句子又是词汇的列表
 28
 29
            sentences_list = []
            for line in f1:
 30
 31
               single_sen_list = line.strip().split(" ")
               while "" in single_sen_list:
 32
                  single sen list.remove("")
 33
               {\tt sentences\_list.append(single\_sen\_list)}
 34
            print u"句子总数: ", len(sentences_list)
 35
 36
            fl.close()
 37
 38
            return sentences_list
 39
     if __name__ == "__main__":
 40
 41
        pass
```

#### 总之, sentences的格式如下:

```
[[我, 是, 2月, ...], [#, 蒙牛, 百, ...], ...]
```

所有的评论文本存为一个列表,每个评论文本又是词汇的列表。 sentences列表的长度就是文本的行数:len(sentences) = 16680

# 利用Keras + LSTM进行文本分类

工具: Keras深度学习库

代码:

```
#!/usr/bin/env python
     # -*- coding: utf-8 -*-
  9
  3
  4
     功能:利用词向量+LSTM进行文本分类
  5
     时间: 2017年3月10日 21:18:34
  6
     import numpy as np
目教)
     np.random.seed(1337) # For Reproducibility
     import pickle
     from keras.preprocessing import sequence
     from keras.models import Sequential
     from keras. layers. embeddings import Embedding
收藏/
     from keras.layers.recurrent import LSTM
     from keras. layers.core import Dense, Dropout, Activation
·
评论
21
     from sklearn.cross_validation import train_test_split
     from Functions import GetLineList
     from Functions.TextSta import TextSta
分裏
    # 参数设置
 25
 26
     vocab dim = 100 # 向量维度
     maxlen = 140 # 文本保留的最大长度
 27
     batch size = 32
 28
 29
     n epoch = 5
     input_length = 140
 30
 31
 32
 33
     def text_to_index_array(p_new_dic, p_sen): #文本转为索引数字模式
 34
         new sentences = []
 35
         for sen in p sen:
 36
            new_sen = []
            for word in sen:
 37
 38
                    new_sen.append(p_new_dic[word]) # 单词转索引数字
 39
 40
                except:
                    new_sen.append(0) # 索引字典里没有的词转为数字0
 41
 42
            new sentences, append (new sen)
 43
         return np. array (new sentences)
 44
 45
 46
 47
     # 定义网络结构
 48
     print u'创建模型...'
 49
 50
         model = Sequential()
         model.add(Embedding(output_dim=vocab_dim,
 51
                           input_dim=p_n_symbols,
 52
                           mask zero=True.
 53
                           weights=[p_embedding_weights],
 54
 55
                           input_length=input_length))
 56
 57
         model.add(LSTM(output_dim=50,
                       activation='sigmoid'.
 58
 59
                       inner_activation='hard_sigmoid'))
         model.add(Dropout(0.5))
 60
         model.add(Dense(1))
 61
 62
         model.add(Activation('sigmoid'))
 63
         print u'编译模型...'
 64
         model.compile(loss='binary_crossentropy',
 65
 66
                      optimizer='adam',
                      metrics=['accuracy'])
 67
 68
 69
         print u"训练..."
         model.fit(p X train, p y train, batch size-batch size, nb epoch=n epoch,
 70
 71
                  validation_data=(p_X_test, p_y_test))
 72
```

```
73
        print u"评估..."
 74
        score, acc = model.evaluate(p_X_test, p_y_test, batch_size=batch_size)
 75
        print 'Test score:', score
 76
        print 'Test accuracy:', acc
 77
 78
 79
    # 读取大语料文本
    f = open(u"评价语料索引及词向量.pkl", 'rb') # 预先训练好的
 -80
    index dict = pickle.load(f) # 索引字典, {单词: 索引数字}
Ξ1)
     word_vectors = pickle.load(f) # 词向量, {单词:词向量(100维长的数组)}
     new_dic = index_dict
     print u"Setting up Arrays for Keras Embedding Layer..."
喜欢6
     n symbols = len(index dict) + 1 # 索引数字的个数,因为有的词语索引为0,所以+1
     embedding_weights = np.zeros((n_symbols, 100)) # 创建一个n_symbols * 100的0矩阵
    for w, index in index_dict.items(): # 从索引为1的词语开始,用词向量填充矩阵
       embedding_weights[index, :] = word_vectors[w] # 词向量矩阵,第一行是0向量(没有索引为0的词
收藏
    语,未被填充)
    # 读取语料分词文本,转为句子列表(句子为词汇的列表)
评论
     print u"请选择语料的分词文本..."
     T1 = TextSta(u"评价语料_分词后.txt")
     allsentences = T1. sen()
分擊6
    # 读取语料类别标签
 97
     print u"请选择语料的类别文本...(用0,1分别表示消极、积极情感)"
 99
     labels = GetLineList.main()
100
101
     # 划分训练集和测试集,此时都是list列表
    X_train_1, X_test_1, y_train_1, y_test_1 = train_test_split(allsentences, labels, test_size=0.2)
102
103
104 # 转为数字索引形式
105
    X_train = text_to_index_array(new_dic, X_train_1)
106
    X_test = text_to_index_array(new_dic, X_test_1)
    print u"训练集shape: ", X_train.shape
107
    print u"测试集shape: ", X_test.shape
108
109
110
    y_train = np.array(y_train_1) # 转numpy数组
    y_test = np. array(y_test_1)
111
113 # 将句子截取相同的长度maxlen,不够的补0
114 print('Pad sequences (samples x time)')
115
    X train = sequence.pad sequences(X train, maxlen=maxlen)
116 X_test = sequence.pad_sequences(X_test, maxlen=maxlen)
117 print('X_train shape:', X_train.shape)
118 print('X_test shape:', X_test.shape)
119
120
    train_lstm(n_symbols, embedding_weights, X_train, y_train, X_test, y_test)
121
122
    if __name__ == "__main__":
123
        pass
```

#### 其中,

```
1 from Functions import GetLineList
```

GetLineList是自定义模块,用于获取文本的类别(存为列表),代码如下:

```
#!/usr/bin/env python
    # -*- coding: utf-8 -*-
  2
  3
  4
     功能: 文本转列表,常用于读取词典(停用词,特征词等)
     使用:给定一个文本,将文本按行转换为列表,每行对应列表里的一个元素
     时间: 2016年5月15日 22:45:23
:=9
目兼)
     import codecs
     import tkFileDialog
喜欢
     def main():
        # 打开文件
        file path = tkFileDialog.askopenfilename(title=u"选择文件")
        f1 = codecs.open(file_path, "r", encoding="utf-8")
收藏/
        print u"已经打开文本: ", file path
\mathbf{Q}_{9}
        # 转为列表
评论
        line list = []
        for line in f1:
          line list.append(line.strip())
分裏
        print u"列表里的元素个数: ", len(line_list)
 25
 26
        fl.close()
 27
        return line_list
 28
 29
     if __name__ == "__main__":
 30
        pass
```

# 实验结果

#### 参考文献:

http://buptldy.github.io/2016/07/20/2016-07-20-sentiment%20analysis/(http://buptldy.github.io/2016/07/20/2016-07-20-sentiment%20analysis/)https://github.com/BUPTLdy/Sentiment-Analysis(https://github.com/BUPTLdy/Sentiment-Analysis)

版权声明:本文为博主 http://blog.csdn.net/churximi 原创文章,未经允许不得转载,谢谢。

▲举报

```
标签:Keras (http://so.csdn.net/so/search/s.do?q=Keras&t=blog) / 深度学习 (http://so.csdn.net/so/search/s.do?q=深度学习&t=blog) / 情感分类 (http://so.csdn.net/so/search/s.do?q=情感分类&t=blog) / 词向量 (http://so.csdn.net/so/search/s.do?q=词向量&t=blog) / LSTM (http://so.csdn.net/so/search/s.do?q=LSTM&t=blog) /
```

Д



guchun8301 (/guchun8301) 4天前 11:04

1楼





喜欢



#### 相关文章推荐

收藏

#### keras + lstm 情感分类 (/weixin 36541072/article/details/53786020)

负面评论如下: 正面评论如下: 使用keras配合lstm效果不错。 代码:#coding:utf-8 ''' Created on 2016-12-20@autho r: 刘帅''' impo...



weixin\_36541072 (http://blog.csdn.net/weixin\_36541072) 2016-12-21 15:50 🕮 2745

#### lstm 做 文本的情感分析 (/xiewenbo/article/details/74492095)

github上可以参考的代码 https://github.com/BUPTLdy/Sentiment-Analysis/blob/master/code/Sentiment\_Istm.py htt p...



🈻 xiewenbo (http://blog.csdn.net/xiewenbo) 2017-07-05 19:50 💢 247



### 精选:深入理解 Docker 内部原理及网络配置 (http://edu.csdn.net/huiyiC ourse/detail/563?utm\_source=blog10)

网络绝对是任何系统的核心,对于容器而言也是如此。Docker作为目前最火的轻量级容器技术,有很 多令人称道的功能,如 Docker 的镜像管理。然而, Docker的网络一直以来都比较薄弱, 所以我们有必要深入了解Docker的 网络知识,以满足更高的网络需求。

#### python 关键字提取 (/zxcasd753651/article/details/52778905)

jieba 关键字提取 import jieba.analyse tags = jieba.analyse.extract\_tags(str, topK=3) #str是提取关键字的内容, topK是



🥯 zxcasd753651 (http://blog.csdn.net/zxcasd753651) 2016-10-10 16:24 🔲 2073

#### 利用 Keras 下的 LSTM 进行情感分析 (/william\_2015/article/details/72978387)

~~~~\*我们用 Keras 提供的 LSTM 层构造和训练一个 many-to-one 的 RNN。 网络的输入是一句话,输出是一个情感 值(积极或消极)。 所用数据是来自 Kaggle 的情感分...



#### 基于LSTM搭建一个文本情感分类的深度学习模型:准确率往往有95%以上 (/u012871493/article/details/72782744)

基于情感词典的文本情感分类 传统的基于情感词典的文本情感分类,是对人的记忆和判断思维的最简单的模拟,如上图。我 们首先通过学习来记忆一些基本词汇,如否定词语有"不",积极词语有"喜欢"、"爱",消...



뾽 u012871493 (http://blog.csdn.net/u012871493) 2017-05-27 16:46 🕮 1237

#### 深度学习与自然语言处理之五:从RNN到LSTM (/malefactor/article/details/50436735)

本文介绍了RNN和LSTM的基本技术原理及其在自然语言处理的应用。

뼸 malefactor (http://blog.csdn.net/malefactor) 2015-12-30 19:01 🕮 34100

#### 在keras 上实践,通过keras例子来理解lastm循环神经网络 (/ma416539432/article/details/53509607)

( **注三** ) 本文是对这篇博文的翻译和实践: http://machinelearningmastery.com/understanding-stateful-lstm-recurrent-neural -netW...



Ma416539432 (http://blog.csdn.net/ma416539432) 2016-12-07 19:05 🕮 5040

# 基于Theano的深度学习(Deep Learning)框架Keras学习随笔-14-递归层 (/ntuwei22007/article/details/49370063)

基于Theano的深度学习(Deep Learning)框架Keras学习随笔-14-递归层 recurrent neural network 上一篇介绍了卷基层, 可以用來构建很常见的卷积神经网络等模...



Maywei22007 (http://blog.csdn.net/niuwei22007) 2015-10-24 00:39 

10686

分享

#### LSTM模型理论总结 (产生、发展和性能等) (/shincling/article/details/49362161)

从LSTM模型原文开始,对LSTM模型提出的动机,所采取的机制、设计的模型、算法进行了梳理。对现今采用的主流的LST M讲行了介绍,对LSTM的性能讲行了阐述和总结。



🜒 shincling (http://blog.csdn.net/shincling) 2015-10-23 15:31 🛚 🕮 51884

#### Keras + LSTM + 词向量 情感分类/情感分析实验 (/churximi/article/details/61210129)

背景简介本人是深度学习入门的菜菜菜鸟一枚... 利用LSTM + word2vec词向量进行文本情感分类/情感分析实验,吸收了网 上的资源和代码并尝试转化为自己的东西~实验环境 win7 64位系统 An...



🥵 churximi (http://blog.csdn.net/churximi) 2017-03-10 23:26 🛚 🕮 5859

#### 主题模型及其在文本情感分析中的应用 (/raycchou/article/details/50983090)

随着Web2.0技术的出现和发展,互联网上(包括门户网站、电子商务网站、社交网站、音/视频分享网站、论坛、博客、微 博等)产生了海量的、由用户发表的对于诸如人物、事件、产品等目标实体的评论信息。例如,下...

RayCchou (http://blog.csdn.net/RayCchou) 2016-03-25 18:06 
Q 2079

#### python机器学习----利用sklearn进行情感分析 (/yyq675886993/article/details/76340470)

import jieba from collections import defaultdict import os from sklearn.feature\_extraction.text impo...

yyq675886993 (http://blog.csdn.net/yyq675886993) 2017-07-29 17:20 🕮 51

#### 关于情感词典计算情感倾向强度值的两种方法 (/mrzhangzz/article/details/60342343)

一、SO-HowNet 情感倾向强度值计算公式为: 其中, Pwords代表正面情感种子词语集合, Nwords代表负面种子词语 集合。 w...

MrZhangZZ (http://blog.csdn.net/MrZhangZZ) 2017-03-04 20:22 496

#### python情感预测 (三) (/weixin\_36541072/article/details/53672538)

对review进行情感正负面判断: #coding=utf-8""" Use positive and negative review set as corpus to train a sentime...

weixin\_36541072 (http://blog.csdn.net/weixin\_36541072) 2016-12-15 16:54 🔲 445

#### 情感分析资源 (/northhan/article/details/50533933)

中文的 http://wenku.baidu.com/view/819b90d676eeaeaad1f3306e.html 情感词典 1.知网的情感词典 - http://www.ke ena...



NORTHhan (http://blog.csdn.net/NORTHhan) 2016-01-17 22:44 🔲 640

# 情感分析 (/northhan/article/details/50533952)

情感分析就是分析一句话说得是很主观还是客观描述,分析这句话表达的是积极的情绪还是消极的情绪。 原理 比如这么一句 话、文字机的画面极好,操作也比较流畅。不过拍照真的太烂了!系统...



🚵 NQRTHhan (http://blog.csdn.net/NORTHhan) 2016-01-17 22:48 🕮 1428

# 

#### 情感分析资源 (/ksearch/article/details/19612481)

转自: http://blog.sina.com.cn/s/blog\_8af1069601019flb.html ------------------------



piaoxuefengqi (http://blog.csdn.net/piaoxuefengqi) 2014-02-21 11:27 🛄 1658

#### 分享

#### 情感分析 (/sinat\_34233802/article/details/71171626)

相关数据集-就是判断一句话的词性,可以从几个方面来看1、分词,将一句话分成几个词语不同的分词方法会产生不同的 效果,利用jieba分词的默认形式(即每个字在词语中会且仅会出现一次) ...

sinat\_34233802 (http://blog.csdn.net/sinat\_34233802) 2017-05-04 16:09 🕮 250

#### 一个 tflearn 情感分析小例子 (/aliceyangxi1987/article/details/76176746)

学习资料: https://www.youtube.com/watch?v=si8zZHkufRY&list=PL2-dafEMk2A7YdKv4XfKpfbTH5z6rEEj3&index =5情感...

aliceyangxi1987 (http://blog.csdn.net/aliceyangxi1987) 2017-07-27 10:51 

2346

#### 情感分析 (/weiyudang11/article/details/52048201)

情感分析情感分析分析文本中作者对特定主体的情感偏好和观点一件,用于决策支持和舆情分析。情感分析可以用于预测电 影票房、改进服务及产品、了解用户的体验等。主题无关的情感分析目前绝大多数针对文本的情感分析都...